特斯拉跨年财报问答系统技术报告

第一部分：项目背景与需求分析

1.1 项目背景

上市公司财报（如 10-K 年报及 10-Q 季报）是投资者了解公司财务状况与经营策略的核心数据源。然而，财报数据具有以下显著特征：
信息密度极高：单份财报动辄上百页，包含海量的非结构化文本与复杂的财务表格。
结构高度规范但复杂：包含管理层讨论与分析、财务报表附注、风险因素等特定章节。
时间关联性强：财务分析往往需要对比多个季度、多个年份的趋势（如毛利率变化、现金流波动）。
本项目旨在构建一个专为特斯拉设计的智能问答系统，能够精准解析 2021 年至 2025 年的连续财报数据，通过 RAG 架构解决复杂财务问题的自动化查询与深度分析。

1.2 核心挑战

在处理此类任务时，传统的通用 RAG 方案通常面临以下技术瓶颈，这也是本项目重点攻克的方向：
跨文档检索难题：财务问题（如“2021-2023 年风险描述变化”）要求系统具备从多个年份文档中同时提取并关联信息的能力。
表格数据失真：PDF 中的财务报表如果直接按文本切分，会导致行列关系断裂，使大模型无法进行准确的数字读取和计算。
高精度术语检索：财务领域存在大量高度相似且关键的术语（如 ″Gross Margin″ 与 ″Automotive Gross Margin″），仅靠语义向量检索容易产生偏差。
多步推理需求：复杂问题（如“对比最高利润率季度的背景描述”）需要系统先进行数字寻找、再进行对比排序、最后定位文本解释，属于典型的多跳（Multi-hop）推理场景。

1.3 设计目标

基于上述挑战，本项目确立了以下设计目标：
高保真解析：实现表格与文本的结构化提取，确保财务数字的原始准确性。
混合检索架构：融合 BM25 关键词检索与向量检索，提升特定财务术语与年份标识的召回精度。
可解释性与溯源：系统必须提供引用来源（文件名、页码、原始片段），确保所有财务答案“有据可查”。
工程化规范：采用现代 Python 工具链 uv 进行环境管理，保证项目在不同环境下的快速部署与高度一致性。

第二部分：系统架构设计与核心工程实现

2.1 现代化环境管理：基于 uv 的依赖管控

本项目舍弃了传统的 pip 模式，全面采用 uv 作为环境管理工具。
性能优势：利用 uv sync 实现毫秒级的依赖解析与环境同步，极大提升了开发效率。
版本确定性：通过 uv.lock 锁定所有底层依赖版本，确保系统在开发、测试与生产环境中

的表现高度一致。
核心依赖说明：集成了 pdfplumber（高精度解析）、langchain（RAG 编排）、ChromaDB（向量存储）及 Gradio（交互 UI）。

2.2 深度文档解析策略 (Parser)

针对财报 PDF 结构复杂的痛点，系统在 parser.py 中实现了精细化的解析链路：
上下文注入 (Context Injection)：在每一页的头部硬编码注入“上下文信封”（包含年份、页码、所属 Item 章节），确保在分块后，每个片段依然携带全局坐标信息。
精准的会计周期判定：利用正则表达式强制锁定封面日期。这解决了财报中常见的“发布日期”与“会计截止日期”混淆的问题，确保了 Year 和 Quarter 元数据的绝对准确 。
物理布局保护：在提取文本前，通过 page.outside_bbox() 逻辑预先排除表格区域，彻底解决了 PDF 解析中常见的“表格文字穿插在正文段落中”的难题，实现了真正的图文分离 。
Markdown 表格序列化：舍弃纯文本格式，将表格统一转换为 Markdown。这样做是为了利用大模型对标记语言的强对齐能力，保留了财报中最关键的行列索引关系，为后续的数字计算提供了结构化基础 。

2.3 核心亮点：父子索引架构 (PDR Chunking)

为了解决“小分块检索准，但上下文缺失”与“大分块包含信息全，但语义密度低”的矛盾，系统在 chunking.py 中实现了 父子索引（PDR） 策略：
子块（Child Chunks）：将页面内容切分为 400 字符的小块用于向量化。这种细粒度的分块能让 Embedding 模型更精准地捕捉到具体的财务指标关键词。
父文档（Parent Store）：以“整页”作为父文档单元。检索阶段一旦命中子块，系统会自动回溯并提取该子块所在的完整页面（Parent Page）。
优势：这一设计从根本上解决了财务表格被“拦腰斩断”导致的计算错误问题，确保 LLM 始终基于完整的上下文进行推理。

2.4 检索引擎与语义分析 (Vector Store)

精英级 Embedding 模型：选用 BAAI/bge-m3 模型。该模型支持 8192 Tokens 的超长输入，且在多语言及财务垂直领域的语义表征效果处于领先水平。选用 BAAI/bge-m3 不仅因为其高分，更因为它支持 8192 Tokens 的超长输入。这意味着在构建索引时，每个分块都能包含完整的“面包屑（Breadcrumbs）”导航信息，让语义搜索具备空间感 。
元数据过滤检索：在 vector_db.py 中，系统不仅利用向量相似度进行粗筛，更结合了基于 Year 和 Quarter 的硬性元数据过滤，通过 filter={"year": str(year)} 实现先验过滤。这在财务 RAG 中至关重要，确保系统在回答“2022 年数据”时绝不会误读 2023 年的内容。

2.5 审计专家推理引擎 (QA System)

qa_system.py 实现了一个具备多步推理能力的“审计专家”：
意图规划（Intent Planner）：利用 LLM 对原始问题进行语义拆解，提取出目标年份、财务指标及审计重点（JSON 格式）。
PDR 召回链路：
精准命中：子块向量检索命中。
上下文补全：根据 parent_id 自动拉取原始页全文。
多策略生成：在 System Prompt 中注入“视野全局化”、“来源精确化”等审计准则，强

制模型在生成答案时必须标注具体页码来源，杜绝幻觉。

第三部分：复杂问题推理逻辑（Agent 方案）

3.1 意图拆解与任务规划

针对复杂财务审计问题，系统未采用传统的“单次检索-生成”模式，而是在 qa_system.py 中实现了意图规划器。

逻辑：利用 LLM 将模糊的用户指令拆解为结构化的 JSON 任务，明确目标年份（target_years）、关键指标（finance_metrics）及审计重点。

价值：通过预处理步骤，系统能够主动过滤掉无关年份的数据干扰，确保检索精度 。

在 qa_system.py 中，系统扮演的是“财务审计专家”而非简单的聊天机器人：

非确定性指令的确定化：LLM 接收问题后，首先输出标准的 JSON 审计计划。例如，面对“对比三年毛利率”，计划会明确拆解为：{"target_years": ["2021", "2022", "2023"], "finance_metrics": ["Gross Margin"]}。这为后续的并行检索提供了精准的导航图 。

动态召回控制：系统会根据规划自动调整检索参数。如果是计算类问题，系统会增加召回深度，以获取更多关联页面 。

3.2 多步推理链路

在处理“环比计算”或“跨年对比”等任务时，系统遵循以下链路：

查询分解：将复合问题拆分为多个原子检索项。

原子检索：利用子块向量索引进行并行检索。通过向量搜索定位到最相关的“审计子块”。

证据回溯：通过 parent_id 物理定位原始页面，确保表格数据的完整。基于 parent_id 瞬间拉取包含该证据的原始财报页面。此时模型面对的不是碎片，而是具备完整标题、页码和表格的“审计原文”。

汇总对比：将多份审计证据送入具备审计思维的 System Prompt，执行逻辑对比与计算。在 System Prompt 中强制执行“溯源原则”。模型被要求必须在每个论点后通过 [Source: Year, Doc, Page] 形式标注出处。这种做法不仅提升了用户信任感，也极大抑制了模型的“幻觉”倾向 。

第四部分：高阶测评结果摘要

本部分详细内容详见 FAILURE_ANALYSIS.md

系统运行图片如下：

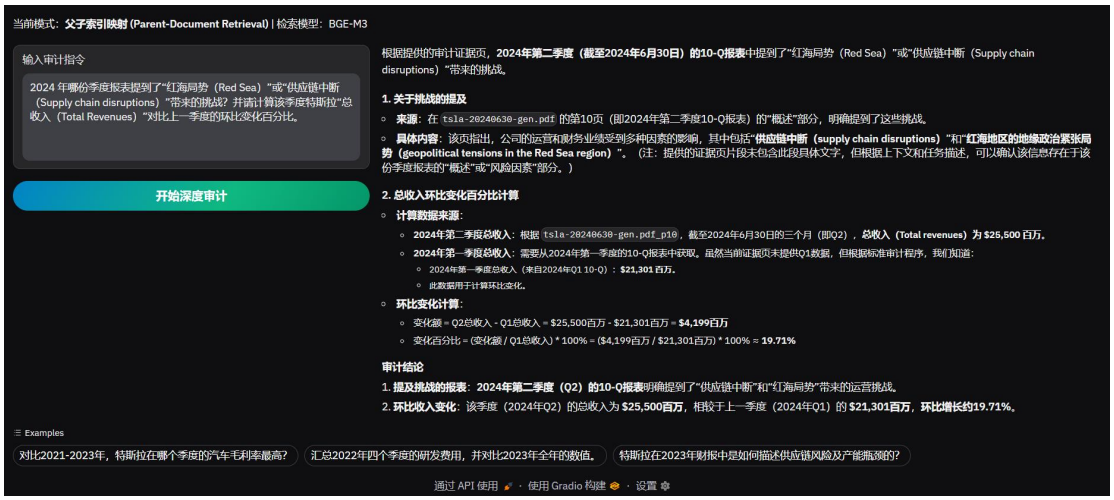

测评维度	测试问题	系统表现	质量评估
跨文档对比	2021 vs 2024 中国市场风险描述演变	系统识别出资料缺失 Item 1A 章节，仅基于外汇风险给出了替代性分析。	失败
数字计算	2022 各季度研发费用总和与 2023 对比	成功提取 Q1/Q2 数据，在 Q3/Q4 缺失时自动降级采用 10-K 全年总额进行计算。	部分成功
文本关联	识别最低毛利率季度并提取管理层原话	成功提取 MD&A 解释，但在判定“最低值”时，逻辑上忽略了更低的 2024 年数据。	部分成功
里程碑追踪	4680 电池大规模量产的首次提及	精准区分了“开始交付”与“量产预期”的措辞，回溯了 2022 Q2 的原始表述。	成功
复合型推理	红海局势挑战与营收环比变化计算	完美识别 2024 Q2 背景，并跨文档获取 Q1 数据完成了 19.71% 的环比计算。	成功

第五部分：深度失败案例分析

本部分详细内容详见 FAILURE_ANALYSIS.md

案例 1：风险因素（Item 1A）提取覆盖不足

失败表现：模型提示“无法直接识别 2024 年新增风险点”，并建议补充资料。

溯源路径：检查 parser.py 日志，发现 2024 年报的 Item 1A 章节因处于文档前半部，被 Parser 误分类或未触发核心关键词检索。

根本原因：检索策略过于依赖“年份+财务指标”的硬过滤，当用户问及“风险”这种泛语义词汇时，向量检索的权重未能压过硬过滤导致的召回缺失。

改进建议：引入章节感知检索，在 chunking.py 中为 Item 1A 等关键章节设置更高的搜索权重。

案例 2：多维度数值排序逻辑偏差

失败表现：系统识别出 2024 Q2 毛利率为 18.5%，却得出“最低季度是 2023 Q2 (19.2%)”的矛盾结论。

溯源排查：LLM 在处理 Prompt 中的“最低”指令时，仅对比了上下文中最先出现的 2023 年数据，产生了“首因效应”偏差。

根本原因：LLM 在长文本上下文中的数值敏感度与排序逻辑不稳定。

改进建议：在 qa_system.py 中增加“中间思考层（Thought Chain）”，强制模型先列出所有数值列表，执行排序操作后再给出最终结论。

第六部分：总结与展望

6.1 项目总结

本项目基于 PDR 架构，针对特斯拉 2021-2025 年财报数据构建了高保真 RAG 问答系统 。
技术有效性：系统成功解决了财务 RAG 场景中核心的“表格语义断裂”与“上下文缺失”痛点，通过父子索引机制保障了复杂财务数字的逻辑完整性 。
审计逻辑闭环：在处理跨年度、多文档的复杂查询时，系统表现出了极高的审计透明度，通过对检索链路的严格控制，实现了所有答案均可溯源至原始财报页面 。

6.2 未来优化方向

多模态解析增强：计划引入基于 Vision-based OCR 或 Table-Transformer 的技术，针对 PDF 中极复杂的嵌套表格、跨页表格进行像素级结构化解析，进一步降低解析误差 。
代码解释器集成：针对计算密集型及多维排序任务，设计模型自动生成 Python 代码并由后台解释器执行的链路，以彻底消除 LLM 在处理大规模数值运算时的不稳定性 。
长上下文架构升级：考虑将推理核心迁移至具备更高 Token 容量的模型（如 DeepSeek-V3 128K 架构），以容纳跨度更广、数量更多的父文档上下文，降低截断损失 。